

TrasparenzAI - Piattaforma per l'analisi e la consultazione della trasparenza amministrativa delle Pubbliche Amministrazioni

Release 1.0.0

CNR - ANAC

Contents

1	Panoramica della soluzione								
2	Architettura della soluzione								
	2.1	Scansic	one dei siti delle PA	3					
3	Com	Componenti principali 5							
	3.1	Public	Sites Service	6					
		3.1.1	OpenAPI e Swagger UI	6					
		3.1.2	Mappa delle PA Italiane	8					
		3.1.3	Sicurezza	9					
	3.2	Config	Service	9					
		3.2.1	OpenAPI e Swagger UI	10					
		3.2.2	Sicurezza	10					
	3.3 Result Service								
		3.3.1	OpenAPI e Swagger UI	10 12					
		3.3.2	Sicurezza	12					
	3.4		Aggregator Service	13					
	5.1	3.4.1	OpenAPI e Swagger UI	13					
		3.4.2	Dipendenze e configurazione	14					
		3.4.3	Sicurezza	14					
	3.5		cheduler Service	14					
	5.5	3.5.1	OpenAPI e Swagger UI	15					
		3.5.2		15					
		3.3.2	Dipendenze e configurazione	13					
4	Risu	Risultati ottenuti 1							
5	Appendice								
	5.1			17					

Piattaforma per l'analisi e la consultazione della trasparenza amministrativa delle Pubbliche Amministrazioni

La trasparenza amministrativa rappresenta un pilastro fondamentale per il buon funzionamento delle istituzioni pubbliche, garantendo ai cittadini, agli operatori economici e agli organismi di controllo la possibilità di accedere in modo semplice e immediato alle informazioni riguardanti l'attività delle Pubbliche Amministrazioni.

Il Decreto Legislativo 33/2013 ha istituito l'obbligo per le amministrazioni di pubblicare una serie di dati, documenti e informazioni nella sezione **Amministrazione Trasparente**, con l'obiettivo di prevenire fenomeni di corruzione e di favorire una maggiore accountability.

Tuttavia, l'applicazione di questa normativa si è rivelata nel tempo complessa e disomogenea, generando difficoltà sia per le amministrazioni stesse, che devono gestire la pubblicazione e l'aggiornamento dei dati, sia per gli utenti finali, che incontrano ostacoli nell'individuazione e nella consultazione delle informazioni.

A fronte di queste criticità, la piattaforma *TrasparenzAI* nasce con lo scopo di semplificare e rendere più efficiente l'accesso e il monitoraggio delle informazioni pubblicate nella sezione Amministrazione Trasparente dei siti delle amministrazioni pubbliche.

La piattaforma è disponibile all'indirizzo:

• https://www.trasparenzai.it

Contents 1

CHAPTER 1

Panoramica della soluzione

La piattaforma *TransparenzAI* nasce con lo scopo di semplificare e rendere più efficiente l'accesso e il monitoraggio delle informazioni pubblicate nella sezione Amministrazione Trasparente dei siti delle amministrazioni pubbliche.

Il problema principale riscontrato è la grande eterogeneità delle modalità di pubblicazione. Ogni amministrazione, pur rispettando formalmente gli obblighi normativi, adotta soluzioni tecniche differenti per l'organizzazione e la struttura della sezione, con variazioni nella denominazione delle sotto-sezioni, nei percorsi di accesso e nella tipologia dei file pubblicati.

Questa frammentazione complica la consultazione delle informazioni e rende estremamente difficoltosa la verifica della loro presenza e conformità. Se per un cittadino alla ricerca di un determinato documento può risultare frustrante dover navigare in siti web strutturati in modo diverso, per ANAC diventa ancora più complesso ed oneroso monitorare il rispetto degli obblighi di pubblicazione su scala nazionale.

La piattaforma risponde a queste necessità introducendo un sistema automatizzato in grado di verificare in modo sistematico la presenza e la struttura delle sezioni Amministrazione Trasparente, fornendo un quadro aggiornato della situazione a livello nazionale.

Questo strumento non si limita a rilevare le irregolarità, ma offre anche un supporto alle amministrazioni per adeguarsi agli standard richiesti, migliorando così il livello complessivo della trasparenza amministrativa.

L'assenza di un meccanismo centralizzato che permetta di uniformare la pubblicazione delle informazioni rappresenta oggi un ostacolo alla piena efficacia della normativa vigente, e la piattaforma si pone l'obiettivo di colmare questa lacuna attraverso l'adozione di strumenti tecnologici avanzati.

L'architettura della piattaforma realizzata è composta da molti componenti integrati tra di loro, qui puoi trovare la documentazione dell'architettura generale, dei singoli componenti e dei risultati di validazione ottenuti.

Se sei interessato al codice sorgente della piattaforma lo puoi trovare su github:

• https://github.com/cnr-anac

Architettura della soluzione

La piattaforma è composta da molti componenti, integrati in una architettura a microservizi, comunicanti tramite il paradigma REST. Ogni microservizio è realizzato con framework opensource e rilasciato a sua volta come software opensource. Anche tutti i componenti infrastrutturali utilizzati nella piattaforma sono opensource, azzerando i costi di licenza e permettendo una totale riusabilità di questa piattaforma per scopi uguali o analoghi a quelli per cui è stata pensata.

È previsto un accesso differenziato alle funzionalità della piattaforma, tramite un sistema di autenticazione e autorizzazione basato sul protocollo OAuth2 e dei ruoli predefiniti inseriti nel token JWT.

Sia l'interfaccia WEB, realizzata dal componente *UI Service*, che ogni API REST, è integrata quindi con un IDP OAuth2. IL servizio in staging realizzato per ANAC utilizza Keycloak come IDP OAuth2.

Il grafico sottostante riassume i componenti principali del sistema.

Rispetto a una tipica architettura a microservizi è stato scelto di non introdurre al momento un API Gateway e un Service Discovery, in quanto la sua adozione potrebbe dipendere dalle politiche di deploy della soluzione. In particolare qualora si decida di usare Kubernetes potrebbe essere indicato utilizzare i meccanismi di API Gateway e Service Discovery disponibili nel coordinatore dei container.

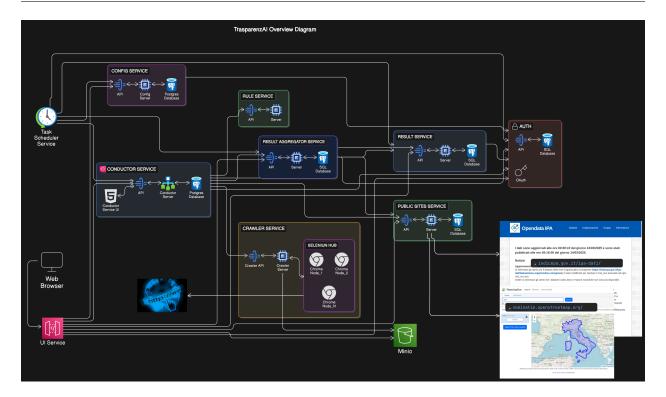
2.1 Scansione dei siti delle PA

La fase di scansione dei siti delle PA viene coordinata dal servizio *Conductor Service*. Questo servizio è basato sul componente opensouce Conductor realizzato da Netflix.

La definizione dei workflow e dei task necessari per compiere tutte le operazioni di analisi, verifica e salvataggio dei risultati delle scansioni dei siti delle PA è definita tramite alcuni file JSON. Questo garantisce una facile configurabilità e adattabilità di questa soluzione a evoluzioni di questa piattaforma oppure a problematiche di crawling e analisi di natura diversa da quella di questo progetto.

L'avvio della fase di scansione di tutti i siti delle PA viene avviata dal microservizio *Task Scheduler Service*, il quale invoca via REST il *Conductor Service* con una cadenza configurabile (per esempio 3 o 4 volte la settimana).

La lista dei siti delle PA è prelevata dal microservizio *Public Site Service*, mentre i risultati delle validazioni sono inseriti sia nel microservizio *Result Service* che nel servizio *Result Aggregator Service*. Inoltre le screenshot delle



pagine HTML ritenute problematiche dal sistema vengono archiviate in uno storage *S3 like*, in particolare nel servizio fornito in staging a ANAC viene utilizzato il prodotto Opensource Minio.

Le regole applicate per la verifica della corrispondenza del sito con la legge sulla trasparenza sono definite tramite il servizio *Rule Service*. Quest'ultimo è stato realizzato in modo da essere un servizio generico di applicazioni di regole di parsing e configurabile tramite file JSON.

Per quando riguarda la parte di crawling e di rendering delle pagine HTML da analizzare la soluzione prevede l'utilizzo di un proprio crawler per prelevare lo streaming hml delle pagine da analizzare e l'adozione di un Selenium Hub per distrubuire su più istanze di Google Chrome il rendering delle pagine HTML che contengono codice javascript da interpretare.

CHAPTER 3

Componenti principali

Il sistema TrasparenzAI è di tipo modulare ed è composta sia da componenti sviluppati ad-hoc per il progetto che da software opensource già disponibili.

I componenti sviluppati per il progetto sono:

- https://github.com/cnr-anac/public-sites-service
- https://github.com/cnr-anac/rule-service
- https://github.com/cnr-anac/result-service
- https://github.com/cnr-anac/result-aggregator-service
- https://github.com/cnr-anac/task-scheduler-service
- https://github.com/cnr-anac/configuration-service
- https://github.com/cnr-anac/workflow-definition
- https://github.com/cnr-anac/ui-service

Alcuni di questi componenti sono stati sviluppati in un ottica di possibile riuso da parte della comunità opensource italiana, alcuni così come sono, altri come esempio per progetti di crawling e analisi di siti di web similari. I componenti stati sviluppati principalmente in Java (con Spring Boot) e Python (FastAPI e Uvicorn) per la parte backend e typescript (AngularJS) per la parte frontend.

I software opensource utilizzati sono:

- · Keycloak
- Postgresql
- Minio
- Selenium Grid
- Selenium Node Chrome
- Conductor
- Traefik

Del software *Conductor* è stato effettuato un fork per introdurre l'autenticazione come client OAuth2 nei task che interagiscono con le API REST della piattaforma.

3.1 Public Sites Service

Public Sites Service è il componente che si occupa di gestire le informazioni principali relative agli enti pubblici italiani ed in particolare i siti istituzionali.

Public Sites Service mantiene nel proprio datastore locale le informazioni egli enti che possono essere inserite/aggiornate tramite gli OpenData di IndicePA, oppure inserite tramite appositi servizi endopoint REST.

L'idea è quella di avere una fonte facile da consultare e estendibile delle informazioni delle organizzazioni pubbliche da analizzare. In particolare sono trattate automaticamente le info utili derivanti IndicePA ma è possibile inserire altri enti da sottoporre a analisi, inserendoli via REST in questo servizio oppure integrando altre fonti esterne sincronizzate automaticamente.

Public Sites Service fornisce alcuni servizi REST utilizzabili in produzione per:

- mostrare la lista degli enti presenti negli OpenData di IndicePA
- inserire ed aggiornare all'interno del servizio le informazioni degli Enti tramite gli OpenData di IndicePA
- geolocalizzare gli Enti italiani tramite il servizio Nominatim di OpenStreetMap
- · visualizzare i dati di un Ente
- mostrare la lista paginata degli Enti presenti nel servizio, con possibilità di filtrarli per codiceCategoria, codiceFiscaleEnte, codiceIpa, denominazioneEnte
- inserire, aggiornare e cancellare le informazioni degli Enti all'interno del servizio (direttamente senza passare da IndicePA)

Il servizio sincronizza e rendere disponibili via REST anche le informazioni dei comuni italiani, prelevendo ogni notte il CSV dal sito dell'ISTAT dei comuni e aggiornando questo info dentro il servizio stesso. Le info dei comuni servono anche per effettuare una geolocalizzazione più precisa degli enti, che su IndicePA sono classificati solamente tramite il codice catastale del comune.

L'aggiornamento dei dati locali al servizio Public Sites Service tramite IndicePA avviene ogni mattina alle 6:30. L'aggiornamento dei dati locali al servizio Public Sites Service tramite il CSV di ISTAT avviene ogni mattina alle 6:40

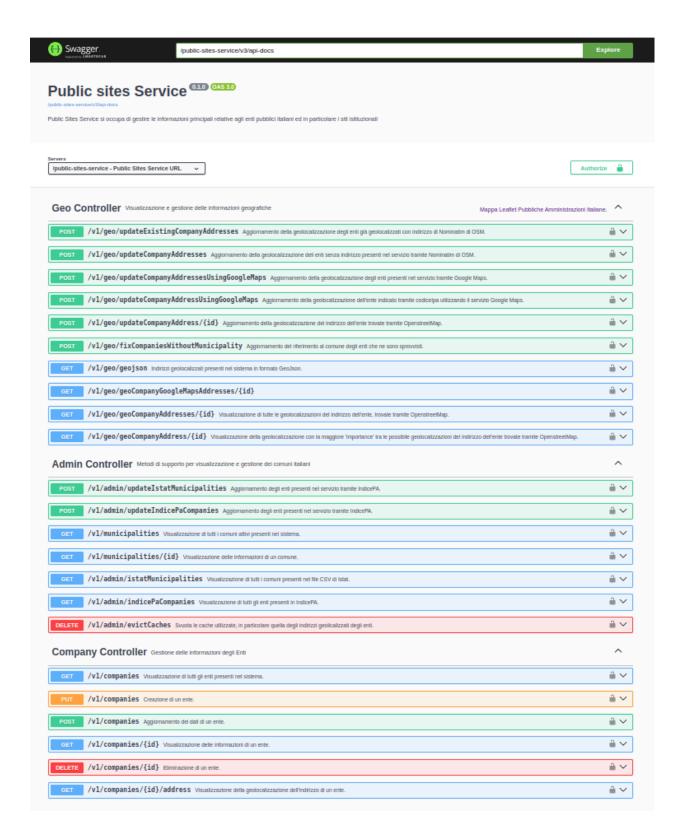
Il codice sorgente di questo componente è disponibile su GitHub:

https://github.com/cnr-anac/public-sites-service

3.1.1 OpenAPI e Swagger UI

Una volta avviato il servizio i servizi REST sono documentati tramite OpenAPI e consultabili all'indirizzo /swagger-ui/index.html.

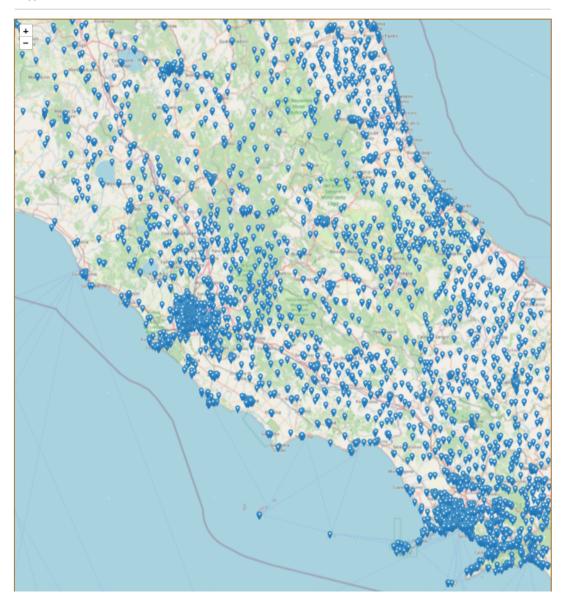
L'OpenAPI del servizio di staging è disponibile all'indirizzo https://dica33.ba.cnr.it/public-sites-service/swagger-ui/index.html.



3.1.2 Mappa delle PA Italiane

Il servizio contiene anche una mappa geografica delle PA italiane realizzata tramite leaflet.

Mappa Pubbliche Amministrazioni Italiane



3.1.3 Sicurezza

Gli endpoint REST di questo servizio sono protetti tramite autenticazione OAuth con Bearer Token. E' necessario configurare l'idp da utilizzare per validare i token OAuth tramite le due proprietà mostrate nell'esempio seguente:

```
- spring.security.oauth2.resourceserver.jwt.issuer-uri=https://dica33.ba.cnr.it/keycloak/
- realms/trasparenzai
- spring.security.oauth2.resourceserver.jwt.jwk-set-uri=https://dica33.ba.cnr.it/
- keycloak/realms/trasparenzai/protocol/openid-connect/certs
```

Per l'accesso in HTTP GET all'API è sufficiente essere autenticati, per gli endpoint accessibili con PUT/POST/DELETE è necessario oltre che essere autenticati che il token OAuth contenga un role ADMIN o SUPERUSER.

3.2 Config Service

Config Service è il componente che si occupa di archiviare e distribuire alcune informazioni di configurazione dei servizi che compongono lo stack del progetto TrasparenzAI.

Config Service mantiene nel proprio datastore locale le configurazioni che sono fornite agli altri microservizi. Le configurazioni possono essere inserite/aggiornate tramite gli appositi endopoint REST presenti in questo servizio.

Le configurazioni disponibili sono fornite sia sotto forma di endopoint REST con le relative CRUD, che nel formato utilizzato da *Spring Cloud Config* attraverso il path **/config**, inserendo il nome del servizio e il profilo richiesto nell'url, come per esempio:

```
$ http GET :8888/config/task-scheduler/default
 "label": null,
 "name": "task-scheduler",
 "profiles": [
      "default"
 ],
  "propertySources": [
      {
          "name": "task-scheduler-default",
          "source": {
              "tasks.fake.cron.expression": "0 46 15 * * ?",
              "test.property1": "testme"
          }
      }
 ],
 "state": null,
  "version": null
```

I microservizi Spring che vogliono utilizzare questo servizio di configurazione centralizzato possono farlo specificando nella propria configurazione tre parametri tipo:

```
spring.config.import=optional:configserver:http://@localhost:8888/config
spring.cloud.config.username=config-service-user
spring.cloud.config.password=PASSWORD_DA_IMPOSTARE_E_CONDIVIDERE_CON_I_CLIENT
```

Dove naturalmente va impostato il corretto URL a cui risponde questo servizio.

3.2. Config Service 9

Il codice sorgente di questo componente è disponibile su GitHub:

• https://github.com/cnr-anac/config-service

3.2.1 OpenAPI e Swagger UI

Una volta avviato il servizio i servizi REST sono documentati tramite OpenAPI e consultabili all'indirizzo /swagger-ui/index.html.

L'OpenAPI del servizio di staging è disponibile all'indirizzo https://dica33.ba.cnr.it/config-service/swagger-ui/index. html.

3.2.2 Sicurezza

L'accesso in lettura alla configurazione di tipo *Spring Cloud Config* disponibile al path **/config** è protetto con autenticazione di tipo *Basic Auth*, i microservizi che vogliono utilizzare questo path per ottenere la configurazione devono utilizzare l'utente e la password sepcificati tramite i parametri *spring.security.user.name* e *spring.security.user.password*, i quali possono essere specificati nel *docker-compose.yml* come nell'esempio seguente:

```
- spring.security.user.name=config-service-user
- spring.security.user.password=PASSWORD_DA_IMPOSTARE_E_CONDIVIDERE_CON_I_CLIENT
```

Invece gli endpoint REST di questo servizio disponibili al path /properties sono protetti tramite autenticazione OAuth con Bearer Token. È necessario configurare l'IDP da utilizzare per validare i token OAuth tramite le due proprietà impostabili nel docker-compose.yml come nell'esempio seguente:

```
- spring.security.oauth2.resourceserver.jwt.issuer-uri=https://dica33.ba.cnr.it/keycloak/

→realms/trasparenzai
- spring.security.oauth2.resourceserver.jwt.jwk-set-uri=https://dica33.ba.cnr.it/

→keycloak/realms/trasparenzai/protocol/openid-connect/certs
```

Per l'accesso in HTTP GET all'API è sufficiente essere autenticati, per gli endpoint accessibili con PUT/POST/DELETE è necessario oltre che essere autenticati che il token OAuth contenga un role ADMIN o SUPERUSER.

3.3 Result Service

Result Service è il componente che si occupa di gestire i risultati delle verifiche sulla corrispondenza dei siti degli enti pubblici italiani in relazione al decreto legge 33/2013 sulla transparenza.

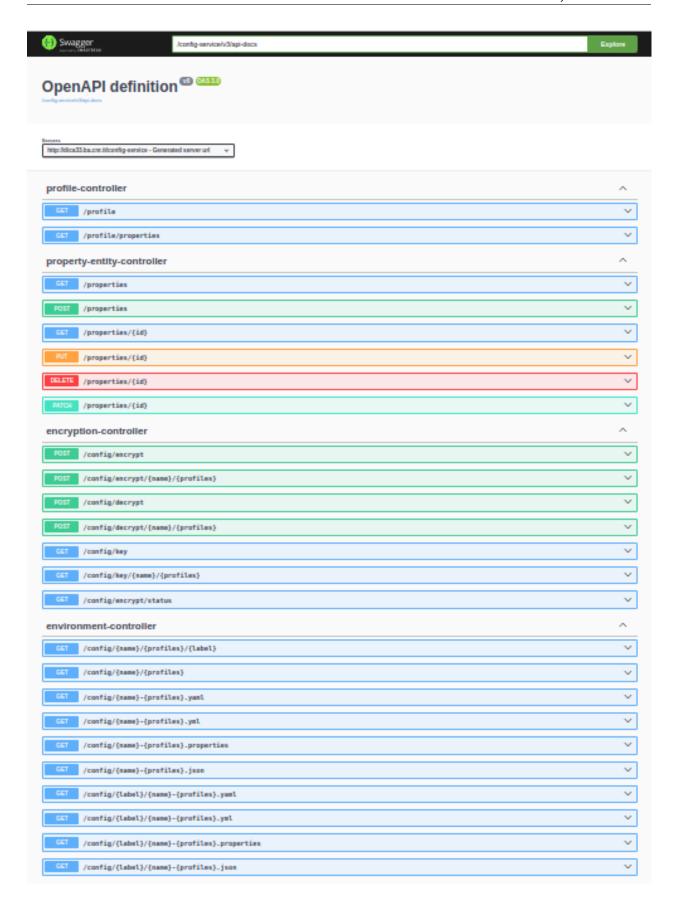
Result Service fornisce alcuni servizi REST utilizzabili in produzione per:

- inserire, aggiornare e cancellare all'interno del servizio le informazioni di una verifica effettuata su un sito web di una PA
- visualizzare i dati di una verifica su un sito web
- mostrare la lista delle verifiche effettuate
- esportare in CSV i risultati delle validazioni presenti

Il codice sorgente di questo componente è disponibile su GitHub:

https://github.com/cnr-anac/result-service

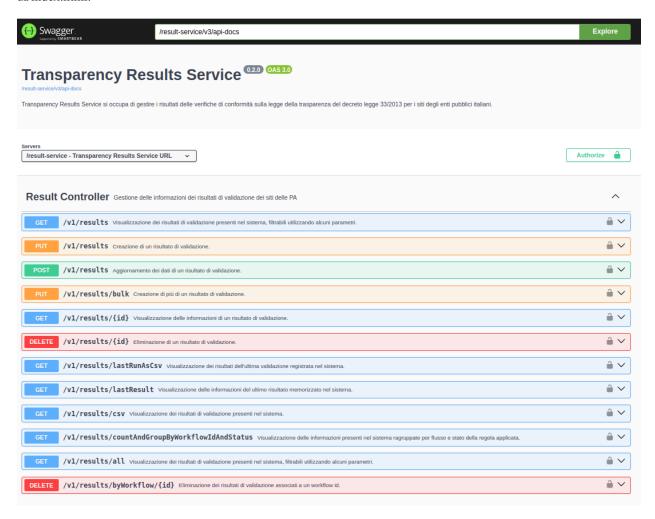
3.3. Result Service 10



3.3. Result Service 11

3.3.1 OpenAPI e Swagger UI

Una volta avviato il servizio i servizi REST sono documentati tramite OpenAPI e consultabili all'indirizzo /swagger-ui/index.html.



L'OpenAPI del servizio di staging è disponibile all'indirizzo https://dica33.ba.cnr.it/result-service/swagger-ui/index. html.

3.3.2 Sicurezza

Gli endpoint REST di questo servizio sono protetti tramite autenticazione OAuth con Bearer Token. E' necessario configurare l'idp da utilizzare per validare i token OAuth tramite le due proprietà mostrare nell'esempio seguente:

- spring.security.oauth2.resourceserver.jwt.issuer-uri=https://dica33.ba.cnr.it/keycloak/
- realms/trasparenzai
- spring.security.oauth2.resourceserver.jwt.jwk-set-uri=https://dica33.ba.cnr.it/
- keycloak/realms/trasparenzai/protocol/openid-connect/certs

Per l'accesso in HTTP GET all'API è sufficiente essere autenticati, per gli endpoint accessibili con PUT/POST/DELETE è necessario oltre che essere autenticati che il token OAuth contenga un role ADMIN o SUPERUSER.

3.3. Result Service 12

3.4 Result Aggregator Service

Result Aggregator Service è il componente che si occupa di gestire i risultati delle verifiche sulla corrispondenza, aggregando i risultati di validazione con altre informazioni sugli enti pubblici prelevate da altri servizi.

Result Aggregator Service fornisce alcuni servizi REST utilizzabili in produzione per:

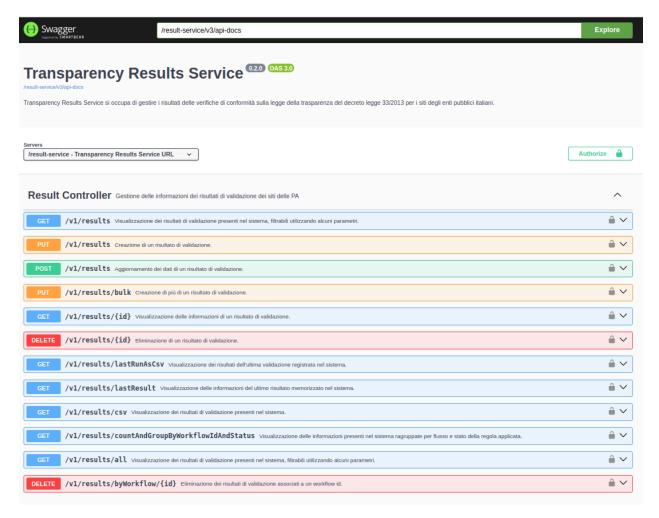
- inserire, aggiornare e cancellare all'interno del servizio le informazioni di una verifica effettuata su un sito web di una PA ed dei dati geografici degli enti pubblici
- · esportare in geoJson i risultati delle validazioni presenti arricchiti con la geolicazzazione degli enti

Il codice sorgente di questo componente è disponibile su GitHub:

• https://github.com/cnr-anac/result-aggregator-service

3.4.1 OpenAPI e Swagger UI

Una volta avviato il servizio i servizi REST sono documentati tramite OpenAPI e consultabili all'indirizzo /swagger-ui/index.html.



L'OpenAPI del servizio di staging è disponibile all'indirizzo https://dica33.ba.cnr.it/result-aggregator-service/swagger-ui/index.html.

3.4.2 Dipendenze e configurazione

Questo servizio ha due dipendenze dagli altri componenti per funzionare:

- il Result Service da cui leggere le info sulle verifiche
- il Public Site Service da cui prelevare le info geografiche delle PA

L'indirizzo di entrambi questi servizi è da configurabile nel file application.properties oppure tramite variabili d'ambiente se avviato tramite Docker.

3.4.3 Sicurezza

Gli endpoint REST di questo servizio sono protetti tramite autenticazione OAuth con Bearer Token. E' necessario configurare l'idp da utilizzare per validare i token OAuth tramite le due proprietà mostrare nell'esempio seguente:

```
- spring.security.oauth2.resourceserver.jwt.issuer-uri=https://dica33.ba.cnr.it/keycloak/
→realms/trasparenzai
- spring.security.oauth2.resourceserver.jwt.jwk-set-uri=https://dica33.ba.cnr.it/
→keycloak/realms/trasparenzai/protocol/openid-connect/certs
```

Per l'accesso in HTTP GET all'API è sufficiente essere autenticati, per gli endpoint accessibili con PUT/POST/DELETE è necessario oltre che essere autenticati che il token OAuth contenga un role ADMIN o SUPERUSER.

Inoltre questo servizio interagisce con il _result_service_ e il _public_site_service_ per prelevare i risultati da aggregare.

Per configurare il client REST che accede a questi due servizi è necessario configurare questi parametri nel docker-compose.yml, in particolare verificare client-id, client-secret e issuer-uri.

Esempio di configurazione dell'environment nel docker-compose.yml:

```
# Generare un Service Account Oidc con questo client-id, oppure cambiare questo valore
- spring.security.oauth2.client.registration.oidc.client-id=result-aggregator
# Client Secret da generare nel Identity Provider e impostare qui
- spring.security.oauth2.client.registration.oidc.client-secret=client_secret_da_generare
# URL dell'issuer OIDC da impostare
- spring.security.oauth2.client.provider.oidc.issuer-uri=https://dica33.ba.cnr.it/
- keycloak/realms/trasparenzai
# - spring.security.oauth2.client.registration.oidc.authorization-grant-type=client_
- credentials #DEFAULT
# - spring.security.oauth2.client.registration.oidc.scope=openid #DEFAULT
# - spring.security.oauth2.client.registration.oidc.provider=oidc #DEFAULT
```

3.5 Task Scheduler Service

Task Scheduler Service è il componente che si occupa di avviare alcuni processi eseguiti a intervalli fissi, come per esempio l'avvio delle scansioni dei siti del PA per la verifica della corrispondenza dei requisiti e la cancellazione dei risultati di scansione più vecchi.

Nell'utilizzo tramite **docker-compose.yml** ricordarsi di impostare la corretta variabile d'ambiente che specifica l'url del config-service da utilizzare:

```
environment:
    confighost:https://dica33.ba.cnr.it/config-service/config
```

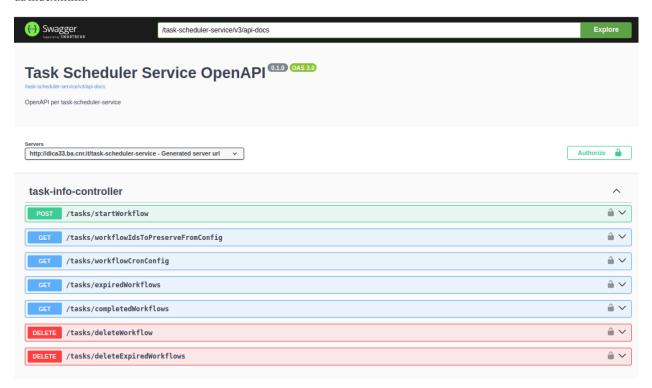
Le informazioni di configurazione dei cron relativi ai workflow possono essere visualizzate all'url /tasks/workflowCronConfig.

Il codice sorgente di questo componente è disponibile su GitHub:

• https://github.com/cnr-anac/task-scheduler-service

3.5.1 OpenAPI e Swagger UI

Una volta avviato il servizio i servizi REST sono documentati tramite OpenAPI e consultabili all'indirizzo /swagger-ui/index.html.



L'OpenAPI del servizio di staging è disponibile all'indirizzo https://dica33.ba.cnr.it/task-scheduler-service/swagger-ui/index.html.

3.5.2 Dipendenze e configurazione

Questo servizio ha quattro dipendenze per funzionare:

- il Config Service da cui prelevare i parametri per l'avvio dei nuovi flussi e la configurazione con le policy di cancellazione dei vecchi risultati
- il Conductor Service per avviare nuovi flussi di scansioni dei siti, per prelevare la lista dei flussi terminati e per cancellare dal Conductor i flussi più vecchi
- il Result Service per cancellare i risultati di validazione più vecchi
- il Result Aggregator Service per cancellare i risultati di validazione aggregati più vecchi

L'indirizzo di questi servizi è da configurabile nel file application.properties oppure tramite variabili d'ambiente se avviato tramite Docker.

Cŀ	JΔ	РΊ	ГΕ	R	4
OI.	\Box			ıι	

Risultati ottenuti

[TODO]

CHAPTER 5

Appendice

5.1 Autori

Autore del codice: Ivan Duca <ivan.duca@cnr.it>

Autore del codice: Dario Elia <dario.eman@gmail.com>

Autore del codice: Claudia Greco <claudia.greco@cnr.it>

Autore del codice: Massimo Ianigro <massimo.ianigro@cnr.it>
Autore del codice: Cristian Lucchesi <cristian.lucchesi@cnr.it>

Autore del codice: Marco Spasiano <marco.spasiano@cnr.it>